УЧЕБНЫЙ МОДУЛЬ · DATA SCIENCE

Извлечение атрибутов из карточек товаров

От правил и NER до мультимодальных моделей: как превратить шумную карточку маркетплейса в структурированные данные, которые двигают поиск и GMV.

Attribute Extraction · Marketplace Catalog

ПОСТАНОВКА · ЗАЧЕМ

Задача качества каталога, которая влияет на поиск и продажи

ВЫВОД Качество атрибутов напрямую двигает поиск, рекомендации, дедупликацию и unit-экономику.

1

Поиск и фильтры

Незаполненный атрибут = товар не находится в фильтре

2

Рекомендации

Атрибуты — фичи для item-to-item и персонализации

3

Дедупликация

Сопоставление одинаковых SKU разных продавцов

4

Цена и аналитика

Сравнение, ценообразование, ассортиментные решения

Атрибут заполнен → Товар попадает в фильтры → Выше CTR и конверсия → **Рост GMV**

Извлечение атрибутов — это про деньги в поиске и каталоге, а не ML-упражнение ради метрики.

ПОСТАНОВКА · ЧТО

Что именно мы извлекаем

ВЫВОД Задача — превратить полуструктурированную карточку в нормализованный набор (атрибут, значение, уверенность)

ВХОД · КАРТОЧКА

- Описание (свободный текст)
- Атрибуты от продавца

→

ПАЙПЛАЙН ИЗВЛЕЧЕНИЯ

Распознать значение
+ нормализовать
+ оценить уверенность

→

ВЫХОД · СТРУКТУРА

```
{
  "бренд": "Samsung",
  "память": "256 ГБ",
  "экран": "6.7 дюйма",
  "цвет": "чёрный"
}
```

Смартфон → бренд, модель, объём памяти, диагональ экрана, ёмкость батареи, цвет
Ноутбук → бренд, процессор, объём RAM, накопитель, диагональ, цвет

ПОЧЕМУ ЭТО СЛОЖНО · 1

Барьеры сложности

ВЫВОД Сложность не в одной модели, а в масштабе, длинном хвосте, мультимодальности и нормализации одновременно.

1

Огромная таксономия

Тысячи категорий × десятки атрибутов в каждой.

2

Длинный хвост (long tail)

Редких значений много, но примеров по каждому мало.

3

Неоднозначность

Нормализация: «алый» = «красный» = «red»

4

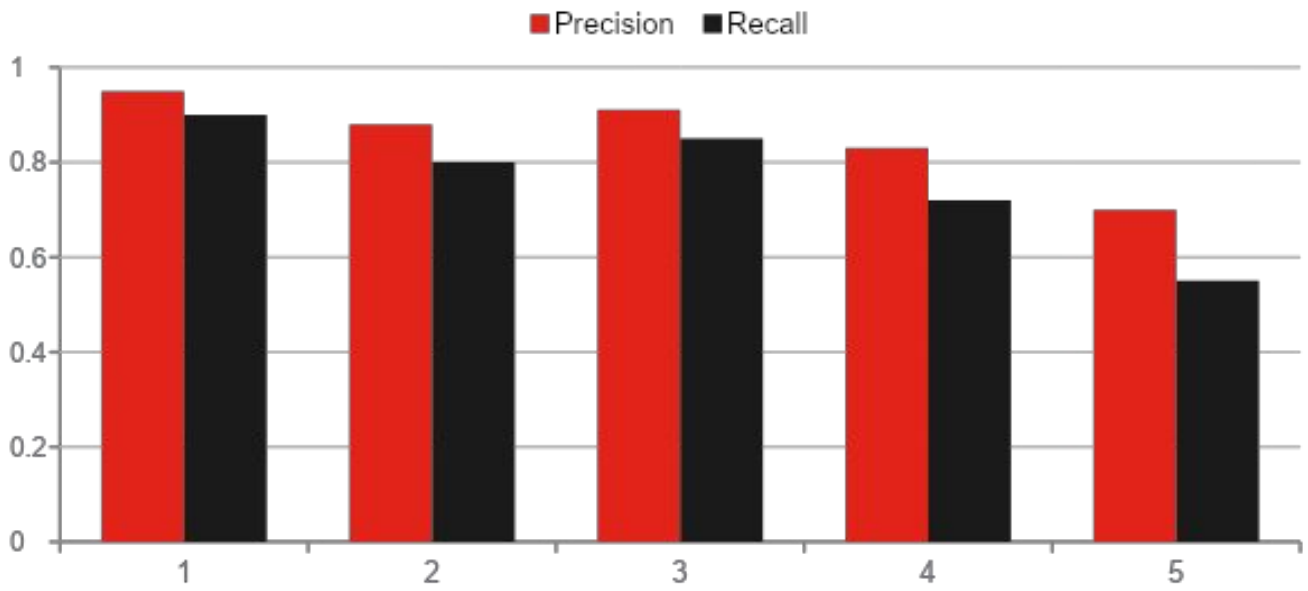
Масштаб и дрейф

Новые SKU и категории каждый день.

ПОЧЕМУ ЭТО СЛОЖНО · 2

Метрики качества

ВЫВОД Per-attribute precision/recall важнее общей accuracy



1. **F1 по каждому атрибуту**

   Не средняя accuracy — она маскирует провал на хвосте.

2. **Coverage**

   Доля карточек, где атрибут заполнен.

3. **Взвешивание по трафику**

   Важнее атрибуты, по которым реально фильтруют.

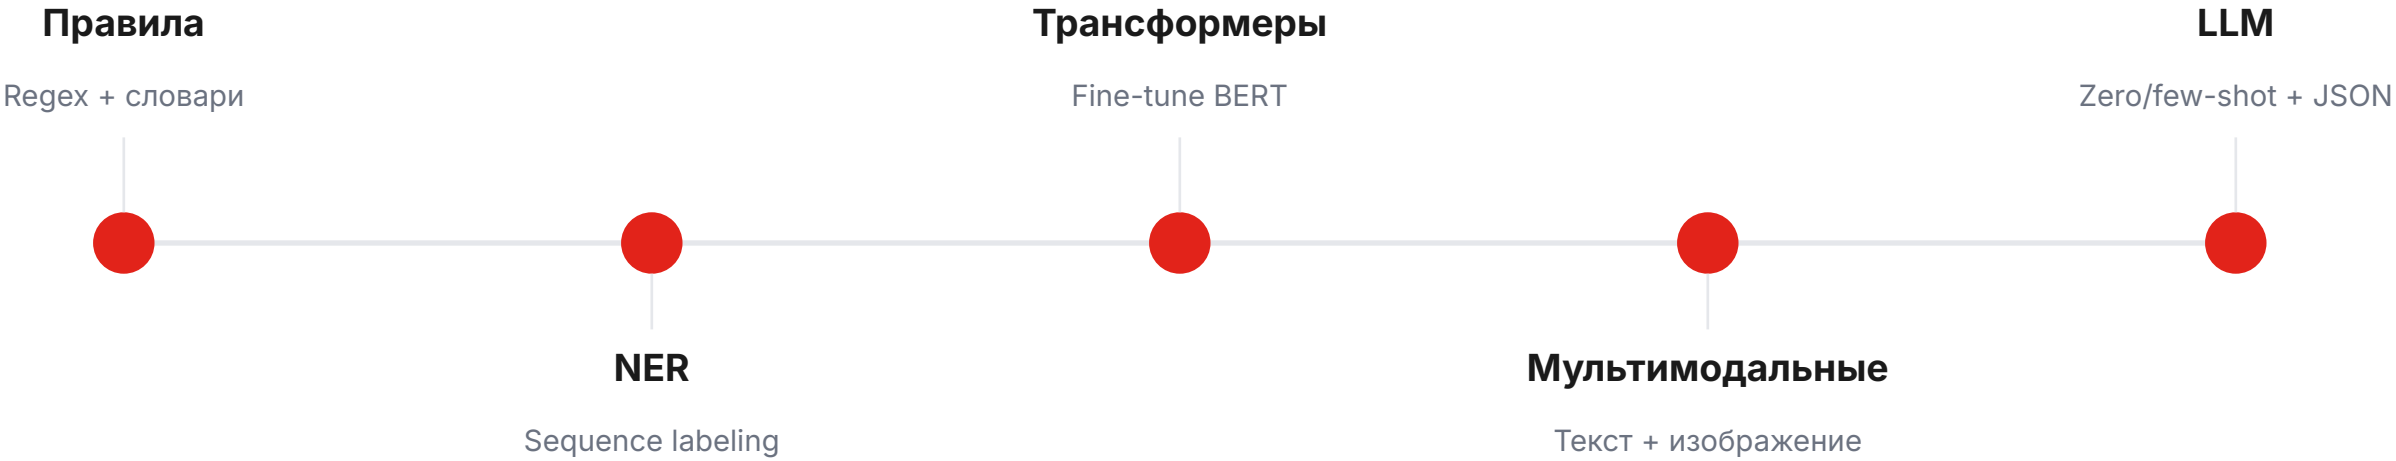
4. **Human eval на gold-сете**

   Эталон, размеченный людьми, по категориям.

МЕТОДОЛОГИЯ · ОБЗОР

Эволюция подходов

ВЫВОД Это путь компромиссов «покрытие ↔ стоимость ↔ поддерживаемость», а не «новое всегда лучше».



В продакшене эти подходы сосуществуют, а не вытесняют друг друга.

МЕТОДОЛОГИЯ · БАЗЛАЙН

Базлайн: правила и словари

ВЫВОД Regex дают значимую часть результата быстро и остаются опорой для проверки моделей.

ВХОД: "Футболка мужская хлопок 100% размер XL красная" → **ПРАВИЛО:** regex размера /\b(XS|S|M|L|XL)\b/ + словарь цветов
ВЫХОД: { размер: "XL", цвет: "красный", материал: "хлопок", пол: "мужской" }

Плюсы

- Прозрачность и контроль
- Скорость, ноль обучающих данных
- Идеален как honest baseline

Минусы

- Не масштабируется на хвост
- Хрупкость к формулировкам
- Ручная поддержка словарей

МЕТОДОЛОГИЯ · КЛАССИЧЕСКИЙ ML

NER и sequence labeling

ВЫВОД Извлечение атрибутов естественно сводится к разметке последовательностей токенов BIO-тегами.

Футболка	мужская	хлопок	размер	XL	красная
O	B-ПОЛ	B-МАТ	O	B-РАЗМ	B-ЦВЕТ

Токены → BIO-теги атрибутов (B — начало значения, I — внутри, O — вне атрибута)

Где выигрывает у правил: ловит значения в свободном тексте и неожиданных формулировках. **Цена:** нужна размеченная обучающая выборка.

МЕТОДОЛОГИЯ · ТРАНСФОРМЕРЫ

Дообученный энкодер под извлечение

ВЫВОД Fine-tune BERT хорошо работает на свободном тексте и контекстных формулировках, но для длинного хвоста всё равно нужны данные и справочники



Multi-task: один энкодер — несколько голов по атрибутам

+ Скачок качества

на хвосте и в свободном тексте

+ Multilingual

один энкодер на разные языки

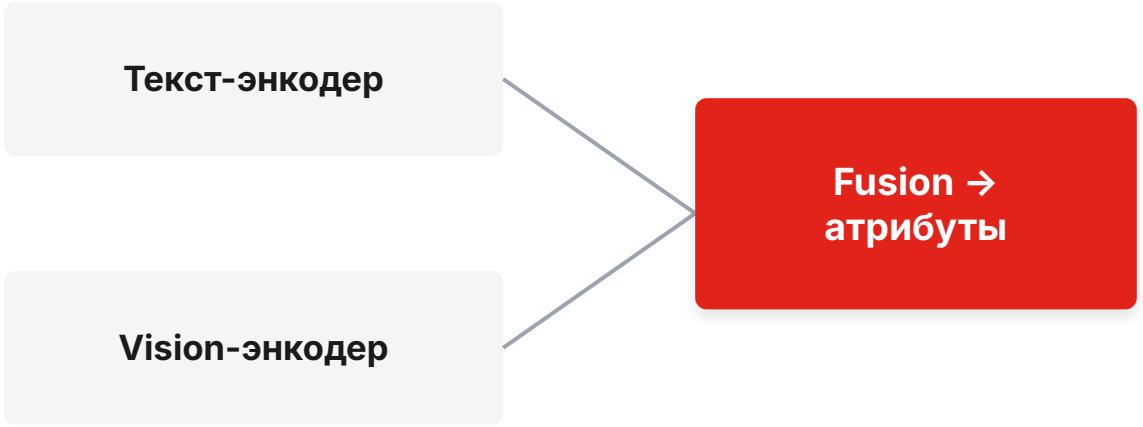
– Стоимость

данные, инференс, поддержка

МЕТОДОЛОГИЯ · ИЗОБРАЖЕНИЕ

Возможность использовать изображение

ВЫВОД В этом задании — только текст



Атрибут	Где сигнал
Бренд	Текст
Размер	Текст
Цвет	Фото (часто)
Принт / узор	Только фото
Форма / фасон	Фото

Кейс: описание молчит про цвет и узор — фото даёт оба атрибута. Цена: усложнение пайплайна и рост стоимости инференса

МЕТОДОЛОГИЯ · LLM

LLM: zero/few-shot и structured output

ВЫВОД LLM закрывают холодный старт и длинный хвост, но требуют контроля галлюцинаций и стоимости.

Критерий	Fine-tuned энкодер	LLM (few-shot)
Cold-start (новые категории)	Слабо — нужна разметка	Сильно — без разметки
Длинный хвост	Средне	Сильно
Стоимость инференса	Низкая	Высокая
Латентность	Низкая	Высокая
Риск галлюцинаций	Низкий	Требует контроля

Прагматичный паттерн: LLM полезны для cold-start и предразметки, но в production их нужно ограничивать схемой, справочниками, проверкой источника значения и порогами уверенности

МЕТОДОЛОГИЯ · РЕШЕНИЕ

Сравнение подходов — решающий слайд

ВЫВОД Правильный ответ — гибрид: правила для ядра, модели для хвоста, LLM для cold-start.

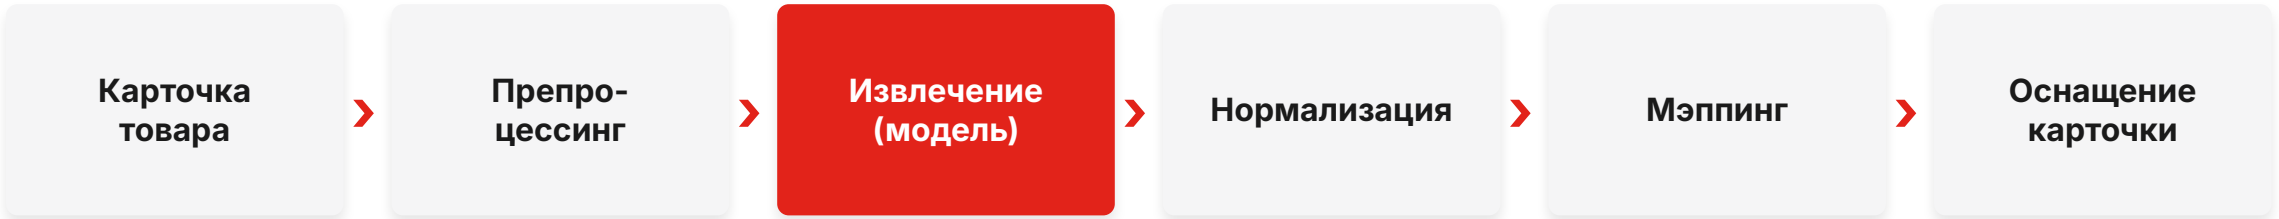
	Качество на хвосте	Стоимость инференса	Нужны данные	Поддер-живаемость	Cold-start
Правила	Низко	**Очень низко**	**Нет**	Средне	**Высоко**
NER	Средне	Низко	Средне	Средне	Низко
Трансформер	**Высоко**	Средне	Много	Средне	Низко
Мультимодал	**Высоко**	Высоко	Много	Низко	Низко
LLM	**Высоко**	Высоко	**Мало**	**Высоко**	**Очень высоко**

Красное = сильная сторона подхода. Ни один столбец не закрывается одним подходом — отсюда гибрид.

ПРОДАКШЕН · ПАЙПЛАЙН

Продакшен-пайплайн end-to-end

ВЫВОД Извлечь значение недостаточно — его нужно привести к формату маркетплейса и проверить

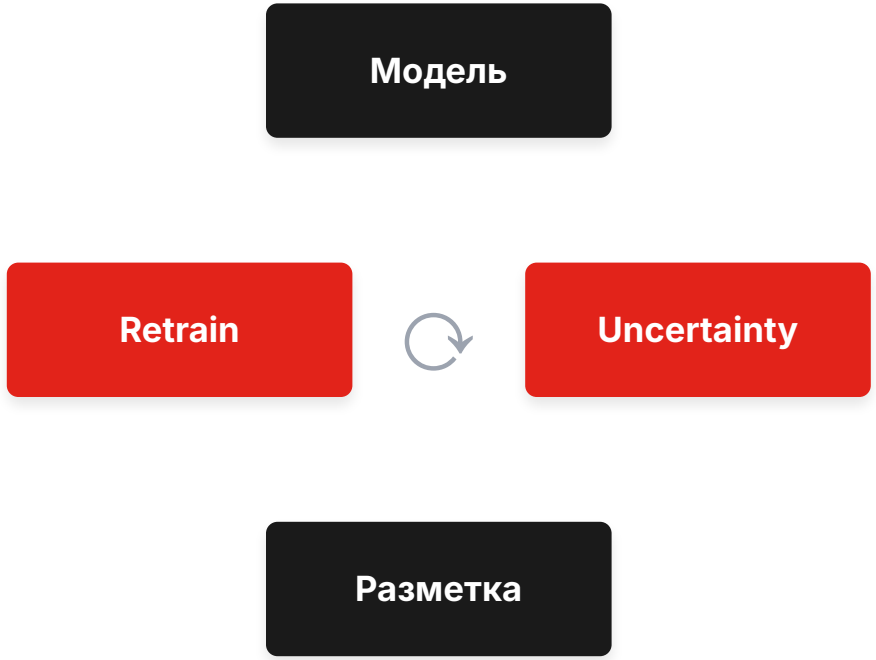


Петля обратной связи: ошибки и low-confidence случаи → ручная разметка → дообучение / обновление правил → улучшение пайплайна

ПРОДАКШЕН · ДАННЫЕ

Данные и стратегия разметки

ВЫВОД Данные — главное конкурентное преимущество. Разметку нужно проектировать, а не докупать объёмом.



1. **Active learning**

   Размечаем то, в чём модель не уверена.

2. **Weak supervision**

   Правила и эвристики как дешёвые лейблы.

3. **LLM-assisted разметка**

   LLM пред-размечает, человек верифицирует.

4. **Gold-сеты по категориям**

   Эталон для честной оценки и контроля дрейфа.

ПРОДАКШЕН · РИСКИ

Риски и типичные ошибки

ВЫВОД Главные риски — галлюцинации LLM, распространение ошибок в поиск и слепые зоны оценки.

Риск	Последствие	Меры снижения
Галлюцинации LLM	Ложные атрибуты ломают фильтры	Structured output + порог уверенности
Стоимость при масштабе	LLM дорого на каждый SKU	Дистилляция, кэш, гибридный роутинг
Eval не покрывает хвост	Метрика красивая, качество плохое	Gold-сеты по редким категориям
Дрейф новых категорий	Падение качества во времени	Мониторинг + петля дообучения
Несправедливость к продавцам	Мелкие SKU хуже обрабатываются	Контроль покрытия по сегментам

На уровне VP первым делом спрашивают про риски — не прячьте их, показывайте вместе с мерами снижения.

ЗАДАНИЕ

Что нужно сделать

ВЫВОД Построить пайплайн, который извлекает обязательные атрибуты из текста карточек

1. **Вход — текст карточки**

   Заголовок, описание и атрибуты продавца

2. **Извлечь и нормализовать**

   Достать обязательные поля и привести значения к каноническому виду.

3. **Бейзлайн → модель**

   Начать с правил/словарей, затем попробовать ML- или LLM-подходом

4. **Оценить честно**

   Per-attribute precision / recall / F1 на gold-сете

ЧТО ПРЕДОСТАВЛЯЕМ

Датасет и обязательные поля

Что будет представлено: датасет карточек товаров и список обязательных атрибутов для извлечения

Датасет карточек товаров

- Текстовые поля: описание, атрибуты продавца
- Размеченная часть для обучения и валидации
- Разные категории товаров (электроника и др.)
- Формат (CSV / JSON)

Обязательные поля для извлечения

- Бренд
- Модель
- Ключевые характеристики (память, диагональ, цвет...)
- Каждое поле — со значением и уверенностью

Точный перечень обязательных полей фиксируется вместе с датасетом.

СДАЧА РАБОТЫ

Обязательные артефакты

ВЫВОД Работа принимается комплектом из шести артефактов.

1

Код или ноутбук

Воспроизводимый код решения

2

README

Инструкция установки и запуска

3

EDA по данным

Анализ полей, пропусков, распределений

4

Пайплайн извлечения

От текста карточки до атрибутов

5

Файл с результатами

Предсказанные атрибуты по карточкам

6

Финальная презентация

Подход, метрики и выводы

Формат сдачи: один репозиторий или архив; запуск решения воспроизводится по README