GoodsAI

Безопасное автозаполнение характеристик товаров для поиска и фильтров

Команда CRUDoshleps · ИТМО

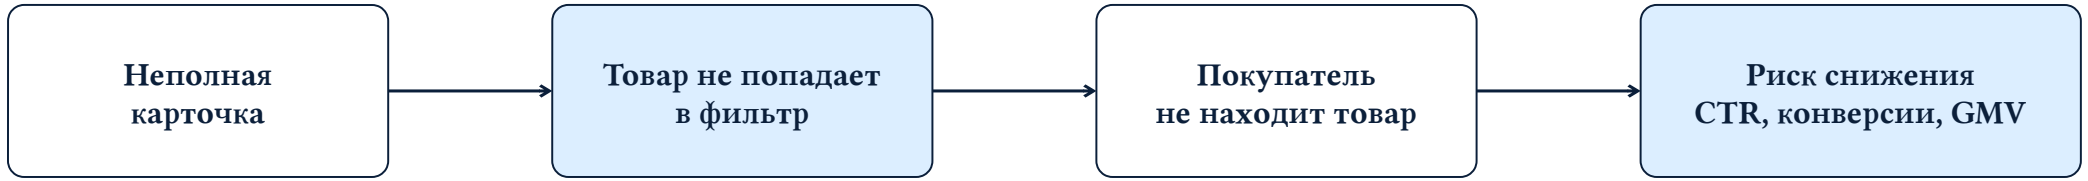
Нестеров Владислав · Альметов Тимур
Алферов Глеб · Садовой Григорий



Заполняем только то, что подтверждено исходным текстом

ВОПРОС 1

Пустая характеристика выключает товар из поиска



Оператор

Ищет характеристику и проверяет её вручную

Продавец

Теряет полноту карточки товара

Покупатель

Не видит подходящий товар в фильтре

Каталог

Получает неполные и несопоставимые поля

Главный пользователь MVP — оператор качества каталога

ВОПРОС 2

Ограничения кейса задают архитектуру

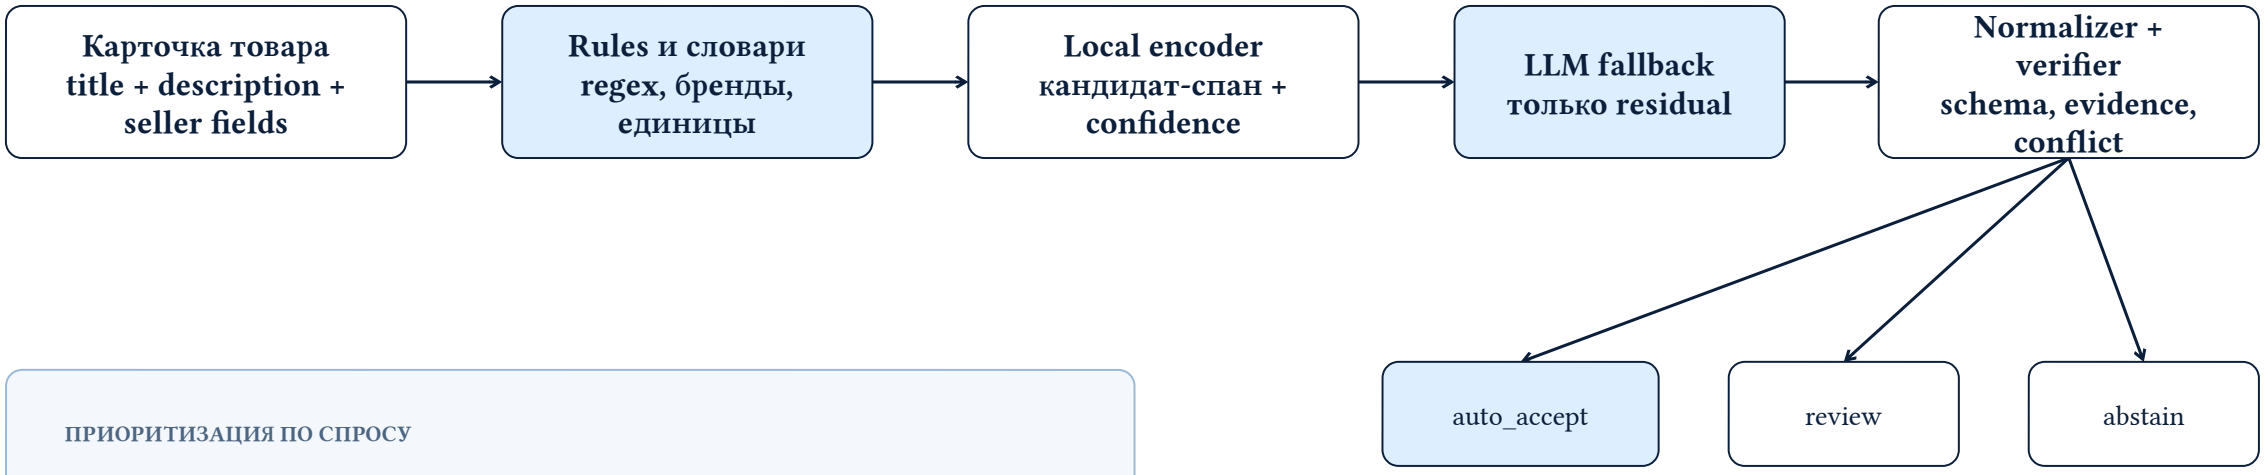
ОГРАНИЧЕНИЕ	ОТВЕТ GOODSAI
Только текст	title, description и поля продавца; без изображений и OCR
Без галлюцинаций	auto_accept требует evidence span в исходном тексте
Нормализация	256GB, 256 Гб, 0.25 ТВ ⟶ 256 ГБ
Контроль стоимости	LLM получает только сложный остаток
Long tail	срезы по категории, атрибуту и продавцу

Нет доказательства в тексте — abstain, а не догадка

ВОПРОС 3

Demand-Aware Evidence Cascade

Каскад качества, риска и стоимости



ПРИОРИТИЗАЦИЯ ПО СПРОСУ

priority = спрос × доля пропусков × ожидаемая точность

Включается после EDA и подтверждения связи query_clicks с SKU

Rules закрывают очевидные форматы. LLM предлагает кандидата только для сложного остатка. Verifier принимает финальное решение.

ВОПРОС 3

Оператор принимает решение по доказательству

КАРТОЧКА ТОВАРА

Смартфон Samsung Galaxy

Описание

Встроенная память 256GB.
Цвет корпуса — графитовый.

Подсвеченные фрагменты — evidence span

АТРИБУТ	ЗНАЧЕНИЕ	CONF.	РЕШЕНИЕ
Объём памяти	256 ГБ	0.98	AUTO ACCEPT
Цвет	чёрный / графитовый	0.71	REVIEW
Батарея	—	—	ABSTAIN

ПРИНЯТЬ | ИСПРАВИТЬ | ОТКЛОНИТЬ

ВОПРОС 4

Ценность для каталога и пользователей

ПОЛЬЗОВАТЕЛЬ

- **Оператор**
  Получает значение, источник и готовое решение для review.
- **Продавец**
  Видит пропуски и конфликты, которые мешают качеству карточки.
- **Покупатель**
  Находит больше релевантных SKU через поиск и фильтры.

БИЗНЕС

- **Каталог**
  Получает нормализованные поля для поиска, сравнения и рекомендаций.
- **Операции**
  Управляют review-нагрузкой и стоимостью на объём SKU.

SELLER QUALITY SCORE

Пустые обязательные поля · конфликты · операторские исправления

ВОПРОС 5

Полезное качество каталога измеряется в срезах

F1 по атрибутам

Точность и полнота отдельно для каждого поля

Valid coverage

Доля валидно заполненных обязательных полей

Precision auto_accept

Безопасность автоматически принятых значений

Review / abstain

Нагрузка оператора и честные отказы

LLM calls / 1 000 SKU

Доля дорогой обработки

Cost / 1 000 SKU

Вычисления, LLM и ручная проверка

Срезы: атрибут · категория · частота значения · продавец · источник текста · маршрут

traffic-weighted quality = Σ(weight × quality) / Σ(weight)

Вес появится после EDA query_clicks

Стоимость и риск управляются маршрутизацией



РИСК	ЗАЩИТА
Галлюцинация	JSON schema + evidence span + verifier
Конфликт источников	Review вместо автоматической записи
Разные форматы	Unit normalizer и словари
Рост затрат	Каскад, cache и cost cap

cost_1000 = local_compute + LLM calls × cost_per_call + review_minutes × operator_rate

Числа появятся после EDA и доступа к модели

Научная опора архитектуры

01	**Ask-and-Verify · EMNLP Industry 2022**	Candidate span и независимая проверка
02	**Explicit Attribute Extraction · ECNLP 2024**	Нормализация и атрибуты для e-commerce поиска
03	**FrugalGPT · 2023**	Каскад более дорогих моделей для сложных случаев
04	**OpenTag · KDD 2018**	Active learning для сомнительных примеров

Исследования обосновывают архитектуру. Метрики GoodsAI считаем на датасете кейса.

Ссылки: aclanthology.org/2022.emnlp-industry.9 · aclanthology.org/2024.ecnlp-1.13 · arxiv.org/abs/2305.051 76 · amazon.science/publications/opentag-open-attribute-extraction-from-product-profiles

Путь к воспроизводимому MVP



СТЕК MVP

DATA	**Python 3.11 · Polars · DuckDB · Jupyter · дедупликация · очистка текста**
SCHEMA	**YAML · Pydantic · regex · RapidFuzz**
ML	**PyTorch · Transformers · русскоязычный BERT encoder**
DELIVERY	**JSON schema · Streamlit/HTML · pytest · GitHub**

Повышаем полезное покрытие каталога без недоказанных значений и инференса LLM для каждой SKU